

Un modello visione-linguaggio sa dire dove si trova? — Risultati del pilot

Imageability urbana e conoscenza geografica nei VLM · pilot del 14 luglio 2026 · modello **gemini-3.5-flash** (versione fissata) · output JSON strutturato · nessuno strumento, nessuna ricerca web · spesa API totale ≈ £2–3

Disegno sperimentale

124 punti a livello strada, bilanciati su **13 città in 8 regioni del mondo** (2 per strato di tessuto urbano per città, dal campione casuale stratificato del progetto). Ogni punto = 4 viste rettilinee (N/E/S/O) da un unico panorama Street View, presentate in un solo prompt multi-immagine. Ogni punto è stato chiesto **due volte**: una con immagini a **testo sfocato automaticamente** (gli stimoli di default dello studio) e una con gli originali intatti — stessi punti, stesso prompt, quindi le due condizioni sono direttamente confrontabili.

Numeri principali

Condizione	n	errore mediano	≤25 km	≤200 km	città corretta	paese	regione
Testo sfocato (default)	124	9,2 km	75,8%	86,3%	72,6%	96,8%	100%
Originale (ablazione)	124	10,4 km	79,0%	89,5%	71,8%	97,6%	100%

1 — Il modello è sorprendentemente bravo. Da quattro foto a livello strada ha indicato la città corretta nel ~72% dei casi, il paese nel ~97% e la regione del mondo nel **100%** — errore mediano di localizzazione sotto i 10 km. Diverse risposte arrivano all'edificio esatto: ha nominato la Harold Washington Library di Chicago (errore 0,0 km) e la via "Am Tierpark" a Berlino (0,1 km) da immagini sfocate.

2 — Sfocare il testo non ha quasi spostato nulla. L'accuratezza sulla città è statisticamente indistinguibile fra le condizioni (72,6% sfocato vs 71,8% originale; scambi per punto 10 vs 9, cioè rumore simmetrico). Le spiegazioni del modello puntano sulla forma urbana: i *Plattenbau* della Germania Est, le corsie tranviarie erbose, il tessuto a schiera, i colori dei riscì, il suolo tropicale rosso. Il riconoscimento sembra guidato dalla **morfologia, non dalla segnaletica** — l'ipotesi centrale del progetto è testabile e mostra già segnale.

3 — Non è la fama a guidare il riconoscimento. Le città meglio riconosciute non sono quelle occidentali famose: Bengaluru 100%, Amman e Cape Town 90%, Accra 80% — e il jolly Ahmedabad (scelto perché distintivo-ma-oscuro) è stato identificato **esattamente, a ~1–2 km, in 7 punti sfocati su 10**. Chicago è ultima nel nominare la città (40%), ma in modo rivelatore: il modello risponde con il *sobborgo specifico corretto* (Des Plaines, Alsip, Elmhurst — errori di 4–20 km), che il confronto rigido dei nomi conta come errore. I due pattern dicono la stessa cosa: la conoscenza del modello segue il **tessuto urbano distintivo, non la celebrità culturale** — esattamente l'effetto imageability che lo studio completo è progettato per misurare.

Accuratezza sulla città per regione (sfocato | originale)

Regione	punti	sfocato	orig.	
MENA e Nord Africa	10	90%	90%	Accra, err. 0,2 km, sfocato: "...il lato nord di Graphic Road ad Accra, Ghana, proprio accanto allo showroom Stallion Motors Changan e alla rampa sud dello svincolo Obetsebi-Lamptey."
Africa subsahariana	20	85%	90%	Berlino, err. 0,1 km, sfocato: "...la via 'Am Tierpark' a Berlino Est... i binari del tram sulla banchina erbosa e i vistosi condomini Plattenbau della Germania Est corrispondono precisamente al tessuto urbano locale."
Asia meridionale	24	83%	79%	Bengaluru, err. 0,3 km, sfocato: "...il famoso incrocio del mercato informatico di SP Road... la scrittura kannada... e i riscì verde-giallo confermano questa posizione esatta."
Oceania	30	73%	80%	
Europa	10	70%	70%	
Asia orientale e SE	10	60%	40%	
America Latina	10	50%	40%	
Nord America	10	40%	40%	

Limite onesto e cosa sistema la fase finanziata

La pipeline di sfocatura v1 (rilevamento testo CRAFT + blur gaussiano) **perde qualcosa**: una verifica visiva degli stimoli conferma che manca insegne inclinate, verticali e piccole-distanti, e 61/124 risposte in condizione sfocata citano ancora testo leggibile. Il risultato sul blur mostra quindi robustezza alla rimozione *parziale* del testo; lo studio completo richiede un passaggio di rilevamento più forte (multi-scala + rotazione, con recall validata su immagini etichettate a mano) prima che l'affermazione sulla morfologia sia inattaccabile. Anche il confronto dei nomi-città richiede alias a scala metropolitana (il caso Chicago). Il pilot è piccolo (~10 punti/città, 1 modello): confermare questi effetti su scala — 50 città, ~10.000 punti, 6+ modelli, il task sui quartieri — è ciò per cui serve la raccolta dati principale.

Pipeline: PostgreSQL/PostGIS · frame stratificato GHSL · acquisizione Street View ancorata al panorama · sfocatura EasyOCR/CRAFT · prompt e scoring versionati; ogni numero è riproducibile dal database. Budget residuo: ~£7 prepagato + £223 di crediti Cloud.

Risultato 4 — il modello ha una mappa mentale simile a quella umana

Stesse 248 risposte, nessuna inferenza aggiuntiva: analisi della *direzione* degli errori di localizzazione. Ipotesi (Lynch / mappe cognitive): gli errori non sono casuali — le predizioni vengono trascinate verso l'**ancora** cognitiva della città.

Gli errori sono centripeti...

Fra le 216 risposte entro la città, il **58% sposta il punto verso il centro** (test dei segni, $p = 0,017$). I punti veri stanno a una mediana di 10,6 km dal centro; le predizioni del modello a 8,9 km — comprime la città sulla sua ancora, esattamente come fanno gli schizzi di mappa umani.

...e il trascinamento cresce con l'anonimato del tessuto

Strato di tessuto urbano	verso il centro	trascinamento mediano
Commerciale / business	50%	0,0 km
Nucleo storico-iconico	56%	0,0 km
Residenziale denso	55%	0,7 km
Bordo periferico	60%	1,1 km
Suburbano a bassa densità	71%	4,2 km

Dove il tessuto è distintivo il modello resta fermo; dove è **senza qualità** (placeless), la predizione scivola verso il centro immaginato. È la distorsione da punto-ancora documentata nella ricerca sulle mappe cognitive umane — che compare spontaneamente in un modello visione-linguaggio, graduata esattamente dagli strati di tessuto che lo studio campiona.

Test dei segni per lo strato suburbano: $p \approx 0,006$ ($n = 42$).

Due firme che corroborano

Aggancio al gazetteer. Cinque punti diversi di Ahmedabad hanno ricevuto la *stessa identica* coordinata predetta (23.023, 72.571) — la posizione canonica da gazetteer di "Ahmedabad" nella città vecchia. Quando è incerto sulla posizione dentro una città, il modello non tira a caso: punta il dito sull'etichetta della mappa, come farebbe una persona.

Le fughe corrono verso le città-ancora. Quando il modello lascia del tutto la città vera (32/248 risposte), scappa quasi sempre verso un'ancora vicina più prominente: Adelaide→Melbourne (×3) e →Perth (×3), Brisbane→Sydney, Bangkok→Chiang Mai, Accra→Lagos, Ahmedabad→Kolkata, Colombo→Dhaka. In cinque coppie sfocato/originale la destinazione della fuga è *identica al chilometro* fra le condizioni — una convinzione stabile su come appaiono quei luoghi, non rumore.

Onestà da pilot: il trascinamento complessivo è modesto (~0,5 km mediano) e il gradiente per strato poggia su ~40 punti per cella; a questa scala è un segnale, non un risultato consolidato. Ma è una *predizione direzionale derivata dalla teoria* (RQ7: cognizione geografica analoga alle mappe mentali umane) che il disegno completo da 10.000 punti e più modelli può confermare o smentire in modo netto — e nessun lavoro pubblicato sulla geolocalizzazione dei VLM ha mai guardato la *direzione* degli errori.